

ĐỀ XUẤT HƯỚNG NGHIÊN CỨU CHO RIVF 2026

Evidence-Efficient Graph Expansion for Multi-Hop Question Answering

Giảm context dư thừa trong GraphRAG nhưng vẫn giữ đủ evidence để trả lời đúng

Mục tiêu

Đề xuất paper ngắn, thiên thực nghiệm, phù hợp nền tảng GraphRAG / Knowledge Graph

Venue

RIVF 2026

Track đề xuất

Track 1 - AI Foundations and Big Data

Ngày chuẩn bị

18/08/2026

Bản báo cáo định hướng nghiên cứu và thiết kế thực nghiệm

Tóm tắt đề xuất

Bài toán cốt lõi: Làm sao giảm lượng context dư thừa khi GraphRAG mở rộng graph cho câu hỏi multi-hop, nhưng vẫn giữ đủ evidence cần thiết để trả lời đúng?

Đề xuất tập trung vào giai đoạn retrieval, cụ thể là sau khi GraphRAG lấy được các seed passages/nodes và mở rộng sang các node lân cận. Thay vì đưa toàn bộ neighborhood vào LLM, hệ thống chấm điểm và chọn lọc một subgraph nhỏ hơn dựa trên độ liên quan ngữ nghĩa với câu hỏi và tín hiệu cấu trúc graph. Mục tiêu không phải tạo một GraphRAG hoàn toàn mới, mà chứng minh rằng selective graph expansion có thể giữ gần như toàn bộ evidence hữu ích trong khi giảm context, token và nhiễu.

Kỳ vọng đóng góp chính
Một cơ chế expand -> score -> prune đơn giản, không cần huấn luyện mô hình lớn, được đánh giá bằng benchmark công khai có gold supporting facts và các metric deterministic.


1. Tổng quan nhanh

Problem	Graph expansion tăng evidence recall nhưng thường kéo theo nhiều context không liên quan.
Proposed method	Selective graph expansion / pruning sau khi tạo candidate neighborhood.
Benchmark chính	HotpotQA - ưu tiên distractor setting.
Benchmark phụ	2WikiMultiHopQA nếu còn thời gian.
Đối thủ chính	Dense RAG, fixed 1-hop, fixed 2-hop, HippoRAG; có thể thêm EfficientRAG hoặc KG ² RAG.
Metric chính	Supporting Fact Recall/F1, Answer EM/F1, context tokens, số passages/nodes, latency.
Claim kỳ vọng	Giữ gần accuracy/evidence recall của full expansion nhưng với ít context hơn.
RIVF track	Track 1 - AI Foundations and Big Data.

2. Bối cảnh và động cơ nghiên cứu

RAG truyền thống thường truy xuất các đoạn văn độc lập dựa trên độ tương đồng ngữ nghĩa. Với câu hỏi multi-hop, evidence cần thiết có thể nằm ở nhiều đoạn và được nối với nhau qua entity hoặc relation. GraphRAG giải quyết hạn chế này bằng cách biểu diễn quan hệ giữa các đơn vị tri thức và mở rộng từ các seed nodes sang neighborhood liên quan.

Tuy nhiên, việc mở rộng graph tạo ra một trade-off rõ ràng. Nếu mở rộng ít, hệ thống có thể bỏ sót evidence ở hop tiếp theo. Nếu mở rộng nhiều, recall có thể tăng nhưng context phình lớn, chứa nhiều node không cần thiết. Context dư thừa làm tăng token cost, latency và có thể làm LLM khó tập trung vào evidence quan trọng.



Vì vậy, paper không đặt mục tiêu cải thiện mọi thành phần của GraphRAG. Nó chỉ xử lý một bottleneck nhỏ nhưng đo được: chọn ra compact evidence subgraph từ tập candidate do graph expansion tạo ra.

3. Phát biểu bài toán

Research problem: Given a multi-hop question and an initial set of retrieved passages/nodes, how can we selectively expand and prune the retrieval graph to preserve answer-supporting evidence while reducing irrelevant context?


Ký hiệu: q là câu hỏi; $G=(V,E)$ là graph retrieval; S_0 là tập seed nodes; C là candidate nodes sau graph expansion; E^* là tập gold supporting evidence; B là context budget. Hệ thống cần chọn $S \subseteq C$ sao cho evidence coverage cao nhưng $|S|$ hoặc số token thấp.

Có thể nhìn bài toán như một tối ưu hai mục tiêu: **maximize EvidenceCoverage(S, E^*)** và **minimize ContextCost(S)**

Trong thực nghiệm, không cần giải bài toán tối ưu tổ hợp phức tạp. Một ranking/pruning heuristic đơn giản đã đủ cho scope của paper RIVF, miễn là baseline và evaluation được kiểm soát tốt.

4. Phương pháp đề xuất

4.1. Pipeline



4.2. Scoring tối giản

Một node/passage ứng viên v có thể được chấm theo: **Score(v) = α * Semantic(q, v) + (1 - α) * GraphRel(v)**

Trong đó Semantic(q,v) có thể lấy từ embedding similarity; GraphRel(v) có thể là một tín hiệu rất đơn giản như độ gần seed, relation relevance, degree-normalized connectivity hoặc score propagation. Sau đó giữ Top-K node hoặc các node vượt threshold. Điểm quan trọng là tránh thêm training burden khi thời gian hạn chế.

Nguyên tắc triển khai

Bắt đầu từ phiên bản nhỏ nhất: semantic similarity + một graph score đơn giản. Chỉ thêm thành phần mới nếu ablation cho thấy cần thiết.

5. Đối thủ và baseline so sánh

Không phải tất cả baseline dưới đây đều giải đúng bài toán pruning. Chúng là các retrieval alternatives để định vị contribution và kiểm tra liệu selective expansion có thực sự mang lại lợi ích.

Method	Loại	Vai trò trong paper	Ưu tiên
Dense RAG	Non-graph	Control baseline: chỉ semantic retrieval	Bắt buộc

Fixed 1-hop expansion	Graph heuristic	Cho thấy lợi ích/chi phí khi mở rộng ít	Bắt buộc
Fixed 2-hop expansion	Graph heuristic	Fuller expansion; recall cao nhưng context lớn	Bắt buộc
HippoRAG	Published graph retriever	Đối thủ graph-based mạnh dùng KG + Personalized PageRank	Nên có
EfficientRAG	Published multi-hop retriever	Đối thủ thiên efficiency và filtering	Nếu setup thuận
KG ² RAG	Published KG-guided RAG	Đối thủ trực diện về seed retrieval + KG-guided expansion	Nếu còn thời gian

Bộ baseline tối thiểu để nộp nhanh: Dense RAG + fixed 1-hop + fixed 2-hop + HippoRAG + Ours. Nếu một published baseline khó reproduce, ưu tiên tính nhất quán và công bằng của setup hơn số lượng đối thủ.

6. Benchmark và dữ liệu

6.1. HotpotQA - benchmark chính

HotpotQA là benchmark multi-hop QA dựa trên Wikipedia, cung cấp supervision ở mức supporting facts. Website chính thức có sẵn train/dev splits, distractor setting, fullwiki setting và evaluation script. Trong distractor setting, mỗi câu hỏi đi cùng 10 paragraphs và hệ thống phải vừa trả lời vừa chỉ ra supporting facts [2].

- Ưu điểm cho đề tài: có gold supporting facts nên đo trực tiếp evidence recall/precision/F1.
- Ưu điểm về thời gian: distractor setting tránh phải index toàn bộ Wikipedia ngay từ đầu.
- Phù hợp với claim: có thể đo xem pruning có loại rác nhưng giữ evidence hay không.

6.2. 2WikiMultiHopQA - benchmark phụ

2WikiMultiHopQA được thiết kế cho đánh giá multi-hop reasoning và cung cấp evidence information chứa reasoning path. Dataset kết hợp structured và unstructured data, phù hợp để kiểm tra generalization của phương pháp sang một benchmark khác [4].

Khuyến nghị: chỉ thêm 2WikiMultiHopQA sau khi HotpotQA pipeline chạy ổn. Với giới hạn thời gian, một benchmark chính được khai thác sâu cùng ablation tốt thường có giá trị hơn hai benchmark nhưng setup thiếu nhất quán.

7. Cách đánh giá

Nhóm	Metric	Ý nghĩa
Evidence	Supporting Fact Recall	Giữ được bao nhiêu gold evidence cần thiết.
Evidence	Supporting Fact Precision	Trong context đã giữ lại, bao nhiêu phần là evidence đúng.
Evidence	Supporting Fact F1	Cân bằng precision và recall.
Answer	Exact Match (EM)	Đáp án có khớp hoàn toàn hay không.
Answer	Answer F1	Độ trùng khớp token với gold answer.
Efficiency	Context tokens / query	Chi phí context thực tế đưa vào LLM.
Efficiency	# passages / # nodes	Kích thước subgraph sau pruning.
Efficiency	Latency / query	Chi phí thời gian retrieval và end-to-

		end.
--	--	------

Metric trung tâm của paper nên là trade-off giữa Supporting Fact Recall và Context Size. Một metric tự định nghĩa như Evidence Recall per Token có thể dùng bổ sung, nhưng không nên thay thế các metric chuẩn.

8. Thiết kế thực nghiệm

8.1. Experiment 1 - Main comparison

Giữ cố định embedding model, graph construction, generator LLM, prompt, corpus và preprocessing. Chỉ thay retrieval strategy. Đây là bảng chính của paper.

Method	Support Recall ↑	Support F1 ↑	Answer F1 ↑	Context Tokens ↓	# Nodes ↓
Dense RAG					
1-hop Graph					
2-hop Graph					
HippoRAG					
Ours					

Kết quả lý tưởng không cần Ours thắng tuyệt đối mọi metric. Một kết quả thuyết phục là Ours giữ gần evidence recall/answer F1 của 2-hop expansion nhưng giảm mạnh context tokens hoặc số nodes.

Mình họa	Support Recall	Answer F1	Avg. passages
Dense RAG	0.68	61	5
2-hop Graph	0.91	68	28
Ours	0.88	69	12

Các số trên chỉ minh họa hình dạng kết quả mong muốn, không phải kết quả thực nghiệm thực tế.

8.2. Experiment 2 - So sánh dưới cùng context budget

Ép các phương pháp dùng cùng budget K (ví dụ K = 5, 10, 15, 20 passages/nodes) và đo Supporting Recall@K. Đây là thí nghiệm quan trọng để tránh lập luận rằng một method tốt hơn chỉ vì được phép retrieve nhiều hơn.

K = 5, 10, 15, 20

Same corpus + same graph + same generator

Compare evidence recall and answer F1 at each budget

8.3. Experiment 3 - Trade-off curve

Vẽ đường cong với trục X là context size hoặc token cost và trục Y là Supporting Fact Recall hoặc Answer F1. Mục tiêu của Ours là nằm gần Pareto frontier: đạt recall/accuracy cao với context nhỏ hơn.

8.4. Experiment 4 - Ablation

Variant	Mục đích
Semantic only	Bỏ graph relevance.
Graph only	Bỏ query semantic relevance.
Random pruning	Sanity check.
Semantic + Graph	Full method.

Sensitivity có thể chạy thêm $\alpha = 0, 0.25, 0.5, 0.75, 1.0$. Đây là thí nghiệm rẻ nhưng giúp giải thích contribution.

9. Research Questions

- 1. RQ1 - Effectiveness: Can selective graph expansion preserve supporting evidence while removing irrelevant context?
- 2. RQ2 - Efficiency: How much retrieval context can be reduced without degrading downstream QA performance?
- 3. RQ3 - Selection mechanism: How do semantic relevance and graph structure contribute to evidence selection?

Mapping giữa RQ và thí nghiệm: RQ1 -> main comparison; RQ2 -> budget curve và trade-off curve; RQ3 -> ablation.

10. Kế hoạch triển khai tối thiểu

- 4. Chuẩn hóa HotpotQA distractor dev set và đọc gold supporting facts.
- 5. Dựng Dense RAG baseline và xác nhận evaluation script chạy đúng.
- 6. Xây graph đơn giản giữa passages/sentences thông qua shared entities hoặc extracted relations.
- 7. Chạy fixed 1-hop và fixed 2-hop để xác nhận pain point: recall tăng cùng context size.
- 8. Thêm selective scoring/pruning; bắt đầu bằng semantic + một graph signal đơn giản.
- 9. Chạy main comparison + budget sweep.
- 10. Thêm HippoRAG nếu reproduction ổn; nếu không, ghi rõ setup và giữ fixed graph baselines làm đối thủ trực tiếp.
- 11. Chạy ablation và tổng hợp trade-off figure.
- 12. Nếu còn thời gian, port sang 2WikiMultiHopQA.

11. Rủi ro và cách kiểm soát

Rủi ro	Tác động	Cách xử lý
Graph construction quá phức tạp	Tốn thời gian, khó debug	Bắt đầu từ entity overlap / relation đơn giản; không train KG extractor mới.
Published baseline khó reproduce	Chậm tiến độ	Chỉ giữ 1 published strong baseline; ưu tiên fixed baselines công bằng.
Ours giảm context nhưng F1 không tăng	Không phải thất bại	Framing theo efficiency: comparable F1 với ít context hơn.
Pruning làm mất evidence	Giảm recall	Sweep threshold/K và dùng gold supporting facts để debug.
Một benchmark chưa đủ thuyết phục	Reviewer hỏi generalization	Thêm 2Wiki nếu pipeline ổn; nếu không, tăng ablation và analysis trên HotpotQA.

12. Phù hợp với RIVF 2026

RIVF 2026 công bố Track 1 - AI Foundations and Big Data, bao gồm machine learning/foundation models, data mining/knowledge discovery, và responsible/trustworthy/reliable AI methods and evaluation. Paper này là một phương pháp retrieval/evaluation cho RAG/GraphRAG, không phụ thuộc một application domain cụ thể, nên Track 1 là lựa chọn tự nhiên hơn Track 2 [1].

CFP hiện cho phép paper tối đa 6 trang theo IEEE A4 và deadline submission đã được gia hạn đến 31/08/2026 [1]. Vì vậy scope nên giữ hẹp: một method nhỏ, một benchmark chính, một published baseline mạnh, fixed expansion controls, metric rõ và một trade-off figure.

Khuyến nghị track

RIVF 2026 - Track 1: AI Foundations and Big Data.

13. Skeleton paper 6 trang IEEE

Phần	Nội dung	Dung lượng gợi ý
1. Introduction	Problem, motivation, 2-3 contributions	~0.7 trang
2. Related Work	RAG, GraphRAG, multi-hop retrieval	~0.6 trang
3. Method	Graph expansion + scoring + pruning	~1.0 trang
4. Experimental Setup	Datasets, baselines, metrics	~0.8 trang
5. Results	Main table, budget curve, ablation	~1.7 trang
6. Conclusion	Kết luận, limitation	~0.3 trang

Phần references chiếm phần dung lượng còn lại. Nếu cần cắt, ưu tiên giữ main table, trade-off figure và ablation; bỏ bớt mô tả engineering.

14. Tiêu chí quyết định có tiếp tục hướng này hay không

Sau một vòng prototype, hướng này đáng tiếp tục nếu quan sát được ít nhất một trong hai tín hiệu sau:

- Ở cùng context budget, Ours có Supporting Fact Recall/F1 tốt hơn fixed expansion hoặc Dense RAG.
 - Ở cùng mức Supporting Recall hoặc Answer F1, Ours dùng ít context tokens/nodes hơn đáng kể.
- Nếu cả hai tín hiệu đều không xuất hiện, nên dừng sớm hoặc đổi scoring/pruning thay vì mở rộng thêm hệ thống. Tiêu chí này giúp bảo vệ thời gian triển khai.

15. Kết luận

Đề tài được đề xuất là một bài toán GraphRAG hẹp, phù hợp với nền tảng Knowledge Graph/RAG và thuận tiện cho thực nghiệm: giảm context dư thừa trong graph expansion cho multi-hop QA nhưng vẫn giữ đủ supporting evidence. Điểm mạnh của hướng này nằm ở benchmark công khai, gold evidence rõ, metric deterministic và baseline dễ hiểu. Contribution có thể nhỏ về thuật toán nhưng vẫn có giá trị nếu trade-off effectiveness-efficiency được chứng minh chặt chẽ.

Cấu hình tối thiểu khuyến nghị: HotpotQA distractor + Dense RAG + fixed 1-hop + fixed 2-hop + HippoRAG + Selective Graph Expansion; đánh giá Supporting Fact Recall/F1, Answer EM/F1, context tokens/nodes và latency. Nếu kết quả tốt, bổ sung 2WikiMultiHopQA để tăng độ tin cậy. Paper nên nộp Track 1 của RIVF 2026.

Tài liệu tham khảo

- [1] RIVF 2026. Call for Papers. <https://rivf2026.org/call-for-papers.html> (truy cập 18/08/2026).
- [2] Z. Yang, P. Qi, S. Zhang, Y. Bengio, W. W. Cohen, R. Salakhutdinov, C. D. Manning. "HotpotQA: A Dataset for Diverse, Explainable Multi-hop Question Answering." EMNLP 2018.
- [3] B. Jimenez Gutierrez et al. "HippoRAG: Neurobiologically Inspired Long-Term Memory for Large Language Models." NeurIPS 2024.
- [4] X. Ho, A.-K. D. Nguyen, S. Sugawara, A. Aizawa. "Constructing A Multi-hop QA Dataset for Comprehensive Evaluation of Reasoning Steps." COLING 2020.
- [5] Z. Zhuang et al. "EfficientRAG: Efficient Retriever for Multi-Hop Question Answering." EMNLP 2024.
- [6] X. Zhu, Y. Xie, Y. Liu, Y. Li, W. Hu. "Knowledge Graph-Guided Retrieval Augmented Generation (KG²RAG)." NAACL 2025.